

POLITECHNIKA WARSZAWSKA

WYDZIAŁ ELEKTRONIKI I TECHNIK INFORMACYJNYCH

WPROWADZENIE DO SZTUCZNEJ INTELIGENCJI

Algorytm SVM

Autor:

Mateusz CHMURZYŃSKI 304021

2 maja 2025

Spis treści

1	Wstęp	2
2	Opis implementowanych algorytmów	2
3	Eksperymenty numeryczne	2
3.1	Wpływ C i γ na jakość modelu	2
3.2	Porównanie z innymi modelami	6
4	Wnioski	7
5	Bibliografia	7

1 Wstęp

Niniejszy dokument jest sprawozdaniem z 4 projektu z WSI. W jego ramach zaimplementowano i przetestowano algorytm SVM.

2 Opis implementowanych algorytmów

W ramach projektu zaimplementowano algorytm SVM do klasyfikacji w postaci dualnej (z mnożnikami Lagrange'a) z jądrem RBF oraz z jądrem wielomianowym. [2] Hiperparametrami dla algorytmu jest C , które waży karę za przekraczanie marginesu przez przykłady oraz γ , które jest parametrem w jądrze RBF

$$K(\mathbf{x}_i, \mathbf{x}_j) = e^{-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|}$$

oraz w jądrze wielomianowym, gdzie dodatkowymi hiperparametrami są d - stopień wielomianu i c_0 - wyraz wolny

$$K(\mathbf{x}_i, \mathbf{x}_j) = (\gamma \mathbf{x}_i^T \circ \mathbf{x}_j + c_0)^d.$$


W eksperymentach numerycznych będziemy badać wpływ C i γ na jakość modelu z jądrem RBF oraz C , γ i d dla jądra wielomianowego (w każdym eksperymencie przyjmujemy $c_0 = 1$). Do optymalizacji wykorzystano bibliotekę *cvxopt* aby rozwiązać zagadnienie optymalizacji kwadratowej dla postaci dualnej.

W ramach projektu zaimplementowano również obliczanie metryk dokładności, precyzji, zupełności i F1-score.

3 Eksperymenty numeryczne


3.1 Wpływ C i γ na jakość modelu

Zaimplementowany algorytm SVM do klasyfikacji wykorzystywał dane dotyczące jakości win [1]. Z całego zbioru danych wybrano losowo 4000 przykładów z ziarnem generatora 42 dla powtarzalności wyników. 20% przykładów przeznaczono do testowania a pozostałe stanowiły zbiór uczący. Ocenę jakości win 0-10 zdyskretyzowano: -1 - słabe wino dla ocen 0-5 oraz 1 - dobre wino dla ocen 6-10. Wartości każdego atrybutu znormalizowano. W ramach pierwszego eksperymentu zbadano różne wartości parametrów C i γ dla jądra RBF i przedstawiono wyniki na mapie cieplnej na rysunku 1.




Rysunek 1: Mapa z wartościami F1-score w zależności od parametrów C i γ dla jądra RBF.

Z powyższego rysunku wynika, że dla użytych danych najlepszą parą hiperparametrów jest $C = 100$ oraz $\gamma = 0.1$. Podobny eksperyment przeprowadzono dla jądra wielomianowego. Mapa dla parametrów $d = 3$ oraz $c_0 = 1$ przedstawiona jest na rysunku 2.




Rysunek 2: Mapa z wartościami F1-score w zależności od parametrów C i γ dla jądra wielomianowego z $d = 3$

Dla jądra wielomianowego dobry wynik uzyskujemy dla $C = 10$ i $\gamma = 1$. Rysunek 2 sugeruje, że lepszych wartości możemy szukać zmieniając zakres parametrów tak jak to przedstawiono na rysunku 3.



Rysunek 3: Mapa z wartościami F1-score w zależności od parametrów C i γ dla jądra wielomianowego z $d = 3$ w innym zakresie.

Niestety nie udało nam się znaleźć lepszych wartości niż poprzednio. Przeprowadzono również eksperyment dla jądra wielomianowego o parametrach $d = 2$ i $c_0 = 1$. Wyniki zaprezentowane są na rysunku 4.



Rysunek 4: Mapa z wartościami F1-score w zależności od parametrów C i γ dla jądra wielomianowego z $d = 2$.

Najlepszą parą parametrów jest $C = 1$ i $\gamma = 1$. Jednak wartość F1-score jest gorsza o ponad 4 punkty procentowe niż najlepsza wartość dla jądra wielomianowego sześciennego.

3.2 Porównanie z innymi modelami

Zaimplementowany algorytm SVM porównano z modelem regresji logistycznej oraz z algorytmem SVM z biblioteki Scikit-learn. Użyto 4000 próbek, przy czym 20% do zbioru testowego. Metryki przedstawiono w tabeli 1. Dla jądra RBF dla własnej implementacji oraz bibliotecznej użyto parametrów $C = 100$ i $\gamma = 0.1$, dla jądra wielomianowego sześciennego $C = 10$, $\gamma = 1$, $c_0 = 1$, a dla jądra wielomianowego kwadratowego $C = 1$, $\gamma = 1$, $c_0 = 1$.

Model	Dokładność	Precyzja	Zupełność	F1-score	Czas [s]
SVM (RBF, własny)	0.785	0.794	0.911	0.848	127.000
SVM (RBF, biblioteczny)	0.759	0.833	0.794	0.813	1.074
SVM (wielomianowe st.3, własny)	0.709	0.862	0.665	0.751	70.614
SVM (wielomianowe st. 2, własny)	0.675	0.879	0.589	0.705	72.487
regresja logistyczna	0.738	0.800	0.803	0.802	0.035
k-NN	0.745	0.799	0.820	0.809	0.014
klasyfikator losowy	0.539	0.693	0.540	0.607	0.004

Tabela 1: Porównanie metryk klasyfikacyjnych dla różnych modeli.

Porównując własną implementację SVM z biblioteczną z jądrem RBF własna implementacja ma wszystkie metryki lepsze od implementacji bibliotecznej, oprócz precyzji. Może to wynikać z dokładności optymalizatorów we własnej i bibliotecznej implementacji, których parametry nie były zmieniane. Pod względem precyzji najlepiej wypadł SVM z jądrem wielomianowym o stopniu 2. Algorytm SVM porównano również z klasyfikatorem losowym, algorytmem k-najbliższych sąsiadów oraz regresją logistyczną, gdzie własna implementacja wypadła najlepiej pod względem metryk. Wadą własnej implementacji jest czas działania algorytmu, który jest znacznie dłuższy od pozostałych. Prawdopodobnie wynika to z użycia lepszych optymalizatorów rozwiązań bibliotecznych.

4 Wnioski

Algorytm SVM okazał się bardzo dobry w porównaniu z biblioteczną implementacją oraz z innymi modelami. Jednak trzeba zwrócić uwagę, że dostrajanie parametrów nie jest zadaniem prostym, ponieważ potrafi być czasochłonne (w szczególności we własnej implementacji) oraz może składać się z wielu etapów, gdzie zmieniamy przedział hiperparametrów i szukamy poprawy w wartościach metryk. Eksperymenty pokazały, że jądro RBF sprawdza się najlepiej pod względem dokładności, zupełności i F1-score, natomiast należy docenić wysoką precyzję jądra wielomianowego o stopniu 2. Jeżeli zależy nam na dobrej klasyfikacji należy wybrać jądro RBF, jeżeli zależy nam na czasie należy rozważyć jądra wielomianowe. Pomimo bardzo wielu gotowych bibliotecznych rozwiązań warto implementować swoje modele, ponieważ mogą dawać lepsze rezultaty,

5 Bibliografia

[1] Zbiór danych jakości win

[2] P. Cichosz, slajdy do wykładu *Zaawansowane uczenie maszynowe*